Chỉ mục và thiết kế kho dữ liệu

Mục tiêu:

- Hiểu ý nghĩa của chỉ mục cho OLAP
- Thiết kế, định nghĩa kho dữ liệu
- Các ví dụ

1

Nội dung

- Đặt vấn đề
- Chỉ mục trên OLAP
- Thiết kế OLAP
- Case study

2

Đặt vấn đề

- Nguyên tắc của chỉ mục: Ánh xạ các giá trị khóa tới các bản ghi để phối hợp truy cập trực tiếp.
- Mục đích: Tăng tốc độ truy cập dữ liệu
- Yêu cầu: Sử dụng thêm bộ nhớ
- Trong các hệ CSDL quan hệ đều ưa chuộng kỹ thuật index B+-Tree

Đặt vấn đề

- Môi trường OLAP chủ yếu là đọc dữ liệu với lượng lớn để trả lời các truy vấn online (time đáp ứng chấp nhận được)
- Cần lựa chọn kỹ thuật đánh chỉ mục (Index) phù hợp
- Có hai kỹ thuật Index hay dùng trong OLAP: Bitmap index và Join Index

Bảng cơ sở

Cust	Region	Type
C1	Asia	Retail
C2	Europe	Dealer
C3	Asia	Dealer
C4	America	Retail
C5	Europe	Dealer

Bitmap index trên Region

RecID	Asia	Europe	America
1	1	0	0
2	0	1	0
3	1	0	0
4	0	0	1
5	0	1	0

Bitmap Index trên Type

RecID	Retail	Dealer
1	1	0
2	0	1
3	0	1
4	1	0
5	0	1

Chỉ mục Bitmap

- Đánh chỉ mục trên các cột cụ thể
- Mỗi giá trị trong cột có một vector bit
- Độ dài của mỗi bảng vector bit bằng số bản ghi có trong bảng cơ sở
- Bit thứ *i* được thiết lập (=1) nếu dòng thứ *i* của bảng cơ sở có giá trị cho cột index
- Bitmap index phù hợp cho các cột có miền giá trị thưa

Bảng cơ sở

Cust	Region	Type
C1	Asia	Retail
C2	Europe	Dealer
C3	Asia	Dealer
C4	America	Retail
C5	Europe	Dealer

Bitmap index trên Region

RecID	Asia	Europe	America
1	1	0	0
2	0	1	0
3	1	0	0
4	0	0	1
5	0	1	0

Bitmap Index trên Type

RecID	Retail	Deale
1	1	0
2	0	1
3	0	1
4	1	0
5	0	1

Chỉ mục Bitmap

Base table

Cust	Region	Type
C1	Asia	Retail
C2	Europe	Dealer
C3	Asia	Dealer
C4	America	Retail
C5	Europe	Dealer

Index on Region

RecID	Asia	Europe	America
1	1	0	0
2	0	1	0
3	1	0	0
4	0	0	1
5	0	1	0

Index on Type

RecID	Retail	Dealer
1	1	0
2	0	1
3	0	1
4	1	0
5	0	1

Region	Bitmap vector
Asia	1 0 1 0 0
Europe	0 1 0 0 1
America	0 0 0 1 0

Type	Bitmap vector
Retail	1 0 0 1 0
Dealer	0 1 1 0 1

Chỉ mục Bitmap

- Cho quan hệ Employees(EmpID, Name, Gender, Rating)

EmpID	Name	Gender	Rating
201	Xuân	M	3
202	Hạ	M	5
203	Thu	F	5
205	Đông	M	4

Index trên Gender

Gender	Bitmap vector
M	1 1 0 1
F	0 0 1 0

Index trên Rating

Rating	Bitmap vector
1	0 0 0 0
2	0 0 0 0
3	1 0 0 0
4	0 0 0 1
5	0 1 1 0

Chỉ mục Bitmap

- Cho quan hệ Employee(EmpID, Name, Gender, Rating)

Rating	Bitmap vector
1	0 0 0 0
2	0 0 0 0
3	1 0 0 0
4	0 0 0 0
5	0 1 1 0

Cho biết số nhân viên có thứ hạng nhỏ hơn 3?
Thao tác trên Bimap vector:

0 0 0 0
0 0 0 0 OR
0 0 0 0

Chỉ mục Bitmap

- Cho quan hệ Employee(EmpID, Name, Gender, Rating)

Gender	Bitmap vector
M	1 1 0 1
F	0 0 1 0

Rating	Bitmap vector
1	0 0 0 0
2	0 0 0 0
3	1 0 0 0
4	0 0 0 0
5	0 1 1 0

Cho biết số nhân viên có thứ hạng nhỏ hơn 3 và giới tính là Nam?
Thao tác trên bit-vector:

0 0 0 0
1 1 0 1 AND
0 0 0 0

Chỉ mục Bitmap

- Cho quan hệ Employee(EmpID, Name, Gender, Rating)

Gender	Bitmap vector
M	1 1 0 1
F	0 0 1 0

Cho biết số phần trăm của các nam nhân viên?

Count(M)/Length(M) = ¾ =75%

Chỉ mục Bitmap

- Thuận lợi của bitmap index:
  - Cho phép sử dụng hiệu quả các phép toán trên bit khi trả lời các truy vấn
  - Giảm không gian lưu trữ hơn kỹ thuật B+tree index
  - Có thể sử dụng mã loạt dài để lưu trữ
  - Sản phẩm thương mại hỗ trợ Bitmap index: Oracle,
  - Làm việc tốt trên các thuộc tính có miền giá trị thưa (Cột có lực lượng nhỏ, lực lượng <= 0.1 % là tốt nhất, từ 0.2% – 1% thì cần xem xét)
- Điểm yếu của bitmap index
  - Không hiệu quả trên các thuộc tính có miền giá trị dày đặc
  - Khó bảo trì, tức là khi kích thước quan hệ thay đổi thì phải tạo bitmap index lại

11

Chỉ mục Bitmap

- Xét quan hệ Tài_Khoản(Số_tài_khoản, Tên_chi_nhánh, Số_dư):

Số_tài_khoản	Tên_chi_nhánh	Số_dư
A_01	Ha Noi	750
A_05	Nghe An	500
A-04	Nghe An	600
A_06	Dong Thap	700
A_09	Ho Chi Minh	400
A_10	Ho Chi Minh	900
A_19	Ho Chi Minh	700
A_30	Da Nang	700
A_68	Long An	350

a) Xây dựng Bitmap index trên thuộc tính Tên_chi_nhánh

b) Xây dựng Bitmap index trên thuộc tính số_dư với các mức: dưới 250, từ 250 đến dưới 500, từ 500 đến dưới 750 và từ 750 trở lên

c) Cho biết số lượng tài khoản ở chi nhánh Nghe An có số dư từ 500 trở lên. Cụ thể hóa các bước trong câu trả lời truy vấn trên và chỉ ra kết quả cuối dựa vào các vector bit

12

Thiết kế kho dữ liệu

- Xây dựng mô hình logic
  - Khối dữ liệu (Cube)
  - Chiều (Dismension)
  - Phân cấp chiều (Hierarchies)
  - Độ đo (Measures)
- Xây dựng mô hình vật lý
  - Sơ đồ hình sao
  - Sơ đồ bông tuyết
  - Sơ đồ chòm sao

Thiết kế kho dữ liệu

- Mục đích của mô hình logic
  - Xác định các khối, các chiều, các độ đo
  - Tinh chỉnh bảng dữ kiện, bảng chiều theo các chủ đề định trước trong bước thiết kế khái niệm
  - Xây dựng các phân cấp chi tiết cho mỗi chiều
- Ví dụ
  - Các khối: Sales, Price, Inventory
  - Các chiều: Product, Time, Geography, Customer
  - Các độ đo: Sum(), AVG(), Count(), Max(),…

Thiết kế kho dữ liệu

- Các chiều thường là các thực thể
  - Mỗi chiều có thể được dùng cho nhiều hơn một khối
  - Các chiều có thể có phân cấp chi tiết
- Ví dụ
  - Chiều: Time
  - Phân cấp chi tiết:

  Year → Quarter →Week → Day

  Hoặc

  Year → Quarter →Month → Day

Thiết kế kho dữ liệu

- Khối
  - Khối là sự kết hợp của các chiều và/hoặc các độ đo
- Ví dụ
  - Sales((Product, Day, Store, Customer), (Quality))

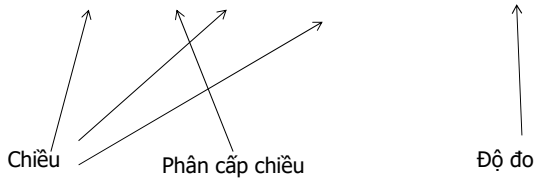

Thiết kế kho dữ liệu

- Kết nhập theo các chiều – phép CUBE
- Ví dụ với Cube_Sales((Item, City, Year), (Quality)) biểu diễn 3 chiều (Item, City, Year)
  - 1 sự kết nhập 3 chiều (Item, City, Year)
  - 3 sự kết hợp 2chiều (Item, City), (Item, Year) và (Year, City)
  - 3 sự kết hợp 1 chiều (Item), (City), (Year)
  - 1 sự kết hợp 0 chiều ()
- Có 2^n sự kết hợp giữa n chiều (số tập con của tập n phần tử)

Sơ đồ kho dữ liệu

- Các sơ đồ
  - Sơ đồ hình sao (star schema): là sơ đồ gồm một bảng trung tâm kết nối với các bảng chiều. Bảng trung tâm được gọi là bảng dữ kiện (fact table)
  - Sơ đồ hình bông tuyết (Snowflake schema): là sự mở rộng sơ đồ hình sao, trong đó một số bảng chiều có các bảng phân cấp khái niệm của chiều đó
  - Sơ đồ chòm sao (Fact constellations schema): là sơ đồ trong đó một số bảng chiều kết nối với nhiều hơn một bảng dữ kiện (bảng chiều dùng chung cho nhiều bảng dữ kiện)

Ví dụ về sơ đồ hình sao

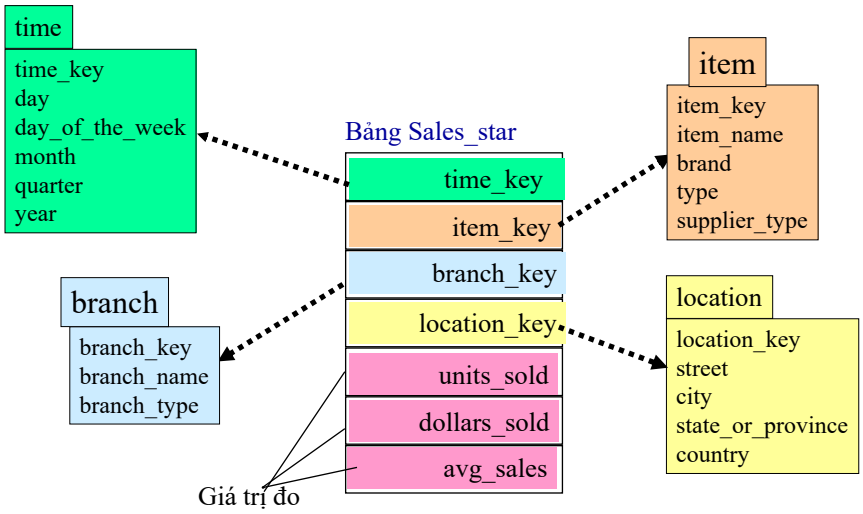

19

Ví dụ về sơ đồ bông tuyết

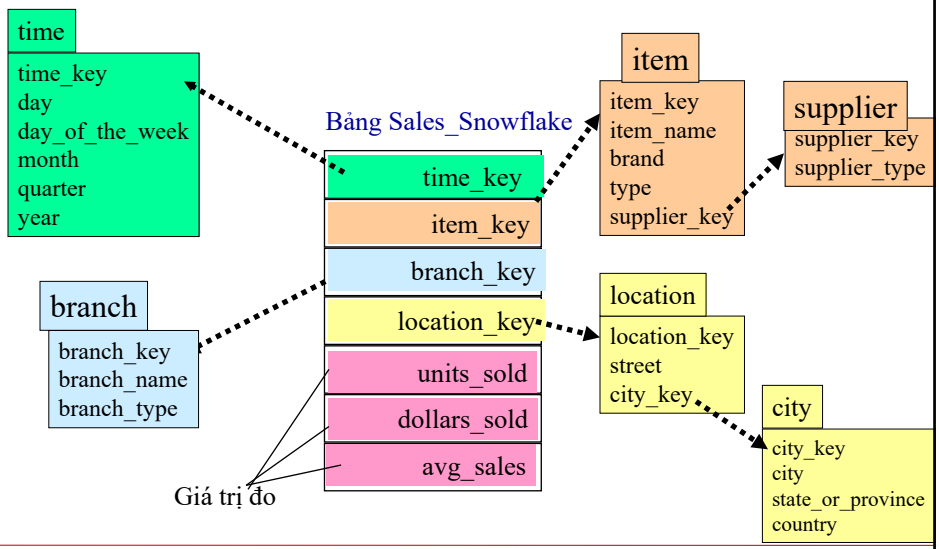

20

Ví dụ về sơ đồ chòm sao

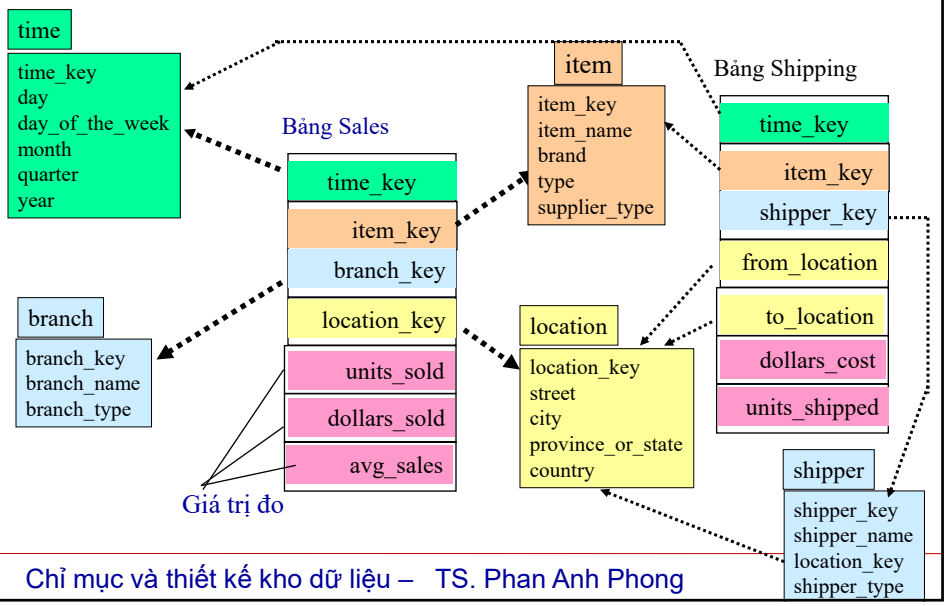

Định nghĩa sơ đồ kho dữ liệu

- Định nghĩa khối - (Bảng sự kiện)
  - Tên khối
  - Các chiều
  - Các độ đo
- Định nghĩa các chiều
  - Tên chiều
  - Các thuộc tính
  - Phân cấp chiều (subdimension_list)
- Chú ý: Dựa vào sơ đồ để định nghĩa

Định nghĩa sơ đồ kho dữ liệu

- Định nghĩa khối - (Bảng sự kiện)
  - Cú pháp:

    define cube <cube_name> [<dimension_list>]: <measure_list>

    Trong đó, measure_list được định nghĩa theo cú pháp measure_name = phép đo()
  - Ví dụ:

    define cube sales_star [time, item, branch, location]:

    dollars_sold = sum(sales_in_dollars),

    avg_sales = avg(sales_in_dollars),

    units_sold = count(*)

Định nghĩa sơ đồ kho dữ liệu

- Định nghĩa các chiều (Dimension Table)
  - Cú pháp:

    define dimension <dimension_name> as (<attribute_or_subdimension_list>)
  - Ví dụ:

    define dimension item as (item_key, item_name, brand, type, supplier_type)
  - Chú ý: khi có phân cấp chiều subdimension_list:

    define dimension item as (item_key, item_name, brand, type, supplier(supplier_key, supplier_type))

Định nghĩa sơ đồ kho dữ liệu

- Trường hợp đặc biệt khi bảng chiều dùng chung
  - Trước tiên định nghĩa khối như ở phần trên
  - Sau đó định nghĩa chiều trong khối

  Cú pháp:

  define dimension <dimension_name> as <dimension_name_first_time> in cube <cube_name_first_time>

  Ví dụ:

  define dimension item as item in cube sales
  - Sử dụng khi định nghĩa trong sơ đồ chòm sao

Định nghĩa sơ đồ hình sao – ví dụ

- define cube sales_star [time, item, branch, location]:

  dollars_sold = sum(sales_in_dollars),

  avg_sales = avg(sales_in_dollars), units_sold = count(*)
- define dimension time as (time_key, day, day_of_week, month, quarter, year)
- define dimension item as (item_key, item_name, brand, type, supplier_type)
- define dimension branch as (branch_key, branch_name, branch_type)
- define dimension location as (location_key, street, city, province_or_state, country)

Định nghĩa sơ đồ bông tuyết – ví dụ

define cube sales_snowflake [time, item, branch, location]:
dollars_sold = sum(sales_in_dollars), avg_sales = avg(sales_in_dollars), units_sold = count(*)
define dimension time as (time_key, day, day_of_week, month, quarter, year)
define dimension item as (item_key, item_name, brand, type, supplier(supplier_key, supplier_type))
define dimension branch as (branch_key, branch_name, branch_type)
define dimension location as (location_key, street, city(city_key, province_or_state, country))

Định nghĩa sơ đồ chòm sao – ví dụ

define cube sales [time, item, branch, location]:
dollars_sold = sum(sales_in_dollars), avg_sales = avg(sales_in_dollars), units_sold = count(*)
define dimension time as (time_key, day, day_of_week, month, quarter, year)
define dimension item as (item_key, item_name, brand, type, supplier_type)
define dimension branch as (branch_key, branch_name, branch_type)
define dimension location as (location_key, street, city, province_or_state, country)
define cube shipping [time, item, shipper, from_location, to_location]:
dollar_cost = sum(cost_in_dollars), unit_shipped = count(*)
define dimension time as time in cube sales
define dimension item as item in cube sales
define dimension shipper as (shipper_key, shipper_name, location as location in cube sales, shipper_type)
define dimension from_location as location in cube sales
define dimension to_location as location in cube sales

Giá trị đo trong khối

- Giá trị đo (measure): tập các giá trị được tính toán dựa vào các cột, hoặc các dòng trong bảng sự kiện của khối đó, thông thường chúng là các giá trị số. Tập giá trị này là rất quan trọng trong việc xử lý, tổng hợp và phân tích dữ liệu trên khối
- Các giá trị đo hay dùng:

  count(), sum(), min(), max(),

  avg(), standard_deviation(),

  median(), rank()…

Tính các giá trị đo trong khối

- Ví dụ: cho sơ đồ dữ liệu OLAP như sau:

time (time_key, day, day_of_week, month, quarter, year);

item (item_key, item_name, brand, type, supplier(supplier_key, supplier_type));

branch (branch_key, branch_name, branch_type) ;

location (location_key, street, city, province_or_state, country)

sales (time_key, item_key, branch_key, location_key, number_of_unit_sold, price)

- Hãy cho biết tổng tiền và tổng các mặt hàng đã bán theo time, item, branch và location?

Tính các giá trị đo trong khối

- Hãy cho biết tổng tiền và tổng các mặt hàng đã bán theo time, item, branch và location?

```
select s.time_key, s.item_key, s.branch_key, s.location_key,
sum(s.number_of_units_sold*s.price), sum(s.number_of_units_sold)
from time t, item i, branch b, location l, sales s
where s.time_key = t.time_key
and s.item_key = i.item_key
and s.branch_key = b.branch_key
and s.location_key = l.location_key
group by CUBE (s.time_key, s.item_key, s.branch_key, s.location_key)
```


Khái quát hóa giá trị thuộc tính

- Các bước:
  - Bước 1. Tuyển tập các dữ liệu liên quan đến công việc (quan hệ khởi tạo) bằng cách sử dụng các truy vấn CSDL thông thường
  - Bước 2. Loại bỏ các thuộc tính không cần thiết
  - Bước 3. Khái quát các thuộc tính
  - Bước 4. Kết nhập theo các độ đo tương ứng, sử dụng các phép toán OLAP: pivot, count, sum, roll-up, cube…
  - Bước 5. Tương tác với người dùng để cải thiện các yêu cầu và trực quan hóa kết quả, đưa ra các luật…

Ví dụ về khái quát hóa dữ liệu

Ví dụ: Hãy mô tả đặc điểm chung của các học viên sau đại học của một trường đại học

- Bước 1. Thu thập dữ liệu để đưa ra *quan hệ khởi tạo* bằng câu lệnh SQL thông thường, chẳng hạn:

  Select name, gender, major, birth_place, birth_date, residence, phone#, gpa

  from students

  where student_status in {"Msc", "PhD" }
- Bước 2, 3: Thực hiện quy nạp theo thuộc tính
- Bước 4. Trình bày kết quả trong quan hệ tổng quát, bảng tổng hợp (cross-tab), hoặc dạng luật
- Bước 5. …

Ví dụ về khái quát hóa dữ liệu

Quan hệ khởi tạo

Name	Gender	Major	Birth-Place	Birth_date	Residence	Phone #	GPA
Jim Woodman	M	CS	Vancouver,BC, Canada	8-12-76	3511 Main St., Richmond	687-4598	3.67
Scott Lachance	M	CS	Montreal, Que, Canada	28-7-75	345 1st Ave., Richmond	253-9106	3.70
Laura Lee	F	Physics	Seattle, WA, USA	25-8-70	125 Austin Ave., Burnaby	420-5232	3.83
…	…	…	…	…	…	…	…
Loại	Giữ lại	Sci,Eng, Bus	Khái quát theo quốc gia	Khoảng tuổi	Thành phố	Loại	Excl, VG,..

Quan hệ khái quát cơ bản

Gender	Major	Birth_region	Age_range	Residence	GPA	Count
M	Science	Canada	20-25	Richmond	Very-good	16
F	Science	Foreign	25-30	Burnaby	Excellent	22
…	…	…	…	…	…	…

Bảng tổng hợp theo Gender, Birth_region

Gender \ Birth_Region	Canada	Foreign	Total
M	16	14	30
F	10	22	32
Total	26	36	62

Bảng tổng hợp theo các thuộc tính khác (có thể có)

Nguyên tắc quy nạp theo thuộc tính

- Tập trung dữ liệu: thu thập các dữ liệu liên quan, các chiều và đầu ra của bước này là *quan hệ khởi tạo*
- Loại các thuộc tính: loại thuộc tính *A* nếu thuộc tính này có nhiều giá trị phân biệt nếu (1) không có thao tác tổng quát trên *A*, hoặc (2) *A* đã được diễn tả ở một thuộc tính khác
- Khái quát hóa thuộc tính: nếu thuộc tính *A* có nhiều giá trị phân biệt nhưng có một thao tác tổng quát trên *A* khi đó ta lựa chọn thao tác đó để khái quát hóa thuộc tính *A*
- Điều chỉnh số thuộc tính của quan hệ khái quát cơ bản: thường là từ 2 đến 8 (gợi ý)
- Tạo lập quan hệ kết quả theo thực tế sử dụng